# 《R 语言应用》课程教案

宁红泉

## 目录

**1 第一章 R 语言介绍** **2**
1.1 课程工具介绍 . . . . . 2
1.2 什么是 R 语言 . . . . . 5
1.3 R 语言能干什么？ . . . . . 5
1.4 R 语言有什么优势 . . . . . 5
1.5 经济与金融计量软件简介 . . . . . 5
1.6 作业 . . . . . 6

**2 第二章 R 语言的下载、安装与启动** **6**
2.1 R 语言的介绍 . . . . . 6
2.2 R 与 Rstudio 软件的界面介绍 . . . . . 7
2.3 R 与 Rstudio 个性化设置 . . . . . 7
2.4 作业 . . . . . 10

**3 第三章 R 语言的基本概念和语法** **10**
3.1 数据对象与数据读写 . . . . . 10
3.2 数据集的基本处理 . . . . . 17
3.3 函数与控制流 . . . . . 24
3.4 绘制基本图形 . . . . . 28
3.5 高级绘图 . . . . . 34
3.6 作业 . . . . . 43

**4 第四章 R 语言实战中医证型关联规则挖掘** **43**

4.1 背景与挖掘目标 . . . . . 43
4.2 分析方法与过程 . . . . . 43
4.3 上机操作 . . . . . 43

**5 第五章航空公司客户价值分析 43**
5.1 背景与挖掘目标 . . . . . 44
5.2 分析方法与过程 . . . . . 44
5.3 上机操作 . . . . . 44

# 1 第一章 R 语言介绍

教学目的：

1.熟悉R软件的特点；
2.了解各种金融计量软件的特点；
3.掌握R计量软件使用范围以及编程基础特点。

教学重难点：

1.重点：掌握R计量软件使用范围以及编程基础特点；
2.难点：了解R计量软件的特点；

## 1.1 课程工具介绍

学生在课程中推进使用 rmarkdown, 它的编辑器是 rstudio。在进行编写 rmarkdown 的时候，首先要简单的学一些 latex, 但在 rmarkdow 中显示中文有点麻烦。中文 LaTeX 文档并非难题，需要借助 CTeX 才行。最佳方式就是使用 tinytex 包。需要注意的是电脑上其他 latex 版本会和它冲突。可以在 Rtudion 上进行设置，
选择 tool–global option–sweave–xelatex，运行 latex 选用 tinytex.
安装 tinytex 的步骤：install.packages(“devtools”),library(devtools),
devtools::install_github(‘yihui/tinytex’)
tinytex::install_tinytex(),
tlmgr_search(‘framed.sty’) % 搜索包含 framed.sty 文件的 LaTeX 包

tlmgr_install('framed') % 安装 framed 包
tlmgr_update() % 更新 TeX Live

latex 的使用：

- documentclass{ctexart} % 或者 ctexrep/ctexbook
- usepackage{ctex} 可以添加文件头：

```
---
documentclass: ctexart
output: rticles::ctex
---
```

### 1.1.1 R 代码段插入

R 代码用 R Markdown 的语法嵌入，即三个反引号开始一段代码```{r}和三个反引号``` 结束一段代码：

```
options(digits = 4)
fit = lm(dist ~ speed, data = cars)
coef(summary(fit))
```

```
##             Estimate Std. Error t value  Pr(>|t|)
## (Intercept)  -17.579     6.7584  -2.601 1.232e-02
## speed          3.932     0.4155   9.464 1.490e-12
```

```
b = coef(fit)
```

上面回归方程中的斜率是 3.9324，完整的回归方程为：

$$Y = -17.5791 + 3.9324x$$

画图可以直接通过命令方式实现：

```
par(mar = c(4, 4, .1, .1), las = 1)
plot(cars, pch = 19)
abline(fit, col = 'red')
```

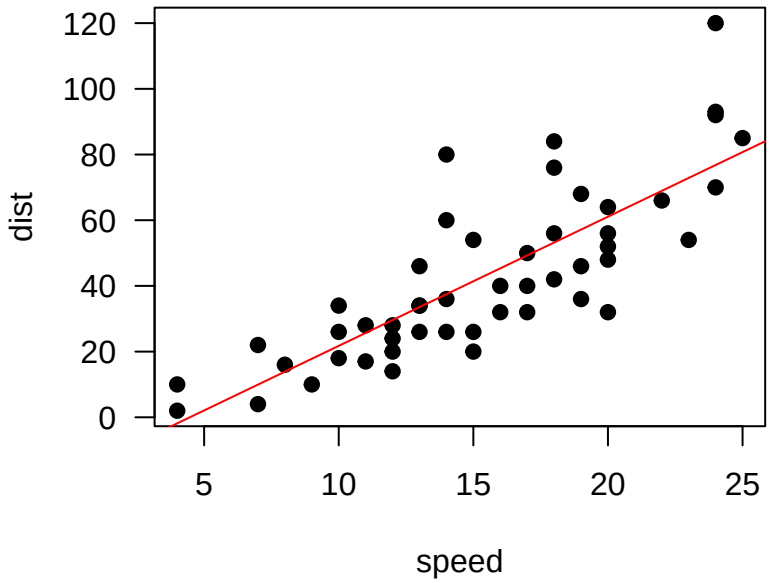


图 1: cars 数据散点图以及回归直线。

### 1.1.2 主题修改

Rstudio 提供的 rticles 模板可能由于种种原因不能满足论文格式的要求，LaTeX 用户就是这样永无止境地调格式。
Pandoc：https://github.com/jgm/pandoc/blob/master/data/templates/default.latex
它是一个文本文件。若熟悉 LaTeX 的话一看就明白，只不过里面有些 Pandoc 变量而已。

### 1.1.3 小结

Rmarkdown 是一款 markdown, 可以通过其他的方式打开。它不能像 word 那样，当时修改就可以看到效果。
但它是一款可以运行 r 代码的 markdown。

## 1.2 什么是 R 语言

R 是用于统计分析、绘图的语言和操作环境。R 是属于 GNU 系统的一个自由、免费、开源的软件，
它是一个用于统计计算和统计制图的优秀工具,R 语言是主要用于统计分析、绘图的语言和操作环境。R 本来是由来自新西兰奥克兰大学的 Ross Ihaka 和 Robert Gentleman 开发。

## 1.3 R 语言能干什么？

- R 是科学计算的强大工具包。
- R 主要擅长统计分析方面工作。
- R 具有顶尖的绘图功能。
- R 的交互式数据分析功能强大且灵活。
- R 可以轻松地从多个数据源导入数据。
- 金融领域数据统计与计算的强大工具。
- 数据挖掘和机器学习领域的必备工具。

## 1.4 R 语言有什么优势

- R 是免费的。
- R 主要擅长统计分析方面工作
- R 具有顶尖的绘图功能
- R 的交互式数据分析功能强大且灵活
- R 可以轻松地从多个数据源导入数据
- R 的更新速度很快，包含最新的大量统计方法和案例
- R 也可以很美。

## 1.5 经济与金融计量软件简介

1. Eviews 软件
2. SAS 软件

3. M atlab
4. SPSS
5. Stata

通过利用实际的软件操作，简单的介绍它们之间的各自特点。重点介绍 R 与 python 软件的开源思想及它们的发展趋势。

### 1.6 作业

1. 统计学与经济计量学的关系是什么？R 软件在其中有什么作用？2. 自行下载 topyra 软件，了解什么是 markdown？

# 2 第二章 R 语言的下载、安装与启动

教学目的：

1.熟悉R语言使用流程；
2.了解选择R语言编程的意义；
3.掌握使用R语言正确设置。

教学重难点：

1.重点：掌握R计量软件界面与特点；
2.难点：正确设置R软件；

### 2.1 R 语言的介绍

为什么选择 R 语言？

- 免费的软件
- 编程方便，语言灵活，图形功能强大
- 优秀的内在帮助系统

- 高质量、广泛的统计分析、数据挖掘平台
- 国际上 R 语言已然是专业数据分析领域的标准 R 的起源
- R 是 S 语言的一种实现。S 语言是由 AT&T 贝尔实验室开发的一种用来进行数据探索、统计分析、作图的解释型语言。

- R 的使用与 S-PLUS 有很多类似之处，两个软件有一定的兼容性。## R 与 Rstudio 软件下载与安装 R 可以在 CRAN(Comprehensive R Archive Network)
  http://cran.r-project.org/mirrors.html 。
  （利用 R 软件进行现场演示操作，然后要求学生课堂练习）

## 2.2 R 与 Rstudio 软件的界面介绍

R 自身带的编辑器很不好用，因此可以寻找很多的替代方案，比如可以选择 Emacs 和 Vim 来替代。这里推荐 Rstudio，它是专门用于 R 语言环境的 IDE。
Rstudio 可以从其官网 http://www.rstudio.com/上免费下载安装。

## 2.3 R 与 Rstudio 个性化设置

### 2.3.1 获取 R 的帮助

R 提供了大量的帮助功能，学会如何使用这些帮助文档可以在很大程度上助力你的编程工作。通过命令窗口输入代码查看帮助。

课堂演示，学生操作练习。
练习例子：查看 tseries 包，查看数据说明。

| 函数 | 功能 |
| --- | --- |
| help.start() | 打开帮助文档 |
| help("plot")或者?plot | 查看函数plot的帮助（引号可以省略） |
| help.search("plot")或者??plot | 以plot为关键词搜索本地帮助文档 |
| example(“plot”) | 函数plot的使用示例（引号可以省略） |
| RSiteSearch("plot") | 以plot为关键词搜索在线文档个邮件列表存档 |
| apropos("plot",mode="function") | 列出名称中含有plot的所有可用函数 |
| data() | 列出当前以加载包中所含的所有可用示例数据集 |
| vignette() | 列出当前已经安装包中所有可能的vignette文档 |
| vignette("plot") | 为主题plot显示指定的vignette文档 |

图 2: help 命令使用

### 2.3.2 R 工作目录

- 工作空间 (workspace) 就是当前 R 的工作环境，它储存着所有用户定义的对象 (向量、矩阵、函数、数据框、列表)。
- 在一个 R 会话结束时，你可以将当前工作空间保存到一个镜像中，并在下次启动 R 时自动载入它。
- 当前的工作目录 (working directory) 是 R 用来读取文件和保存结果的默认目录。
- 可以使用函数 getwd( ) 来查看当前的工作目录，或使用函数 setwd( ) 设定当前的工作目录。
- 如果需要读入一个不在当前工作目录下的文件，则需要在调用语句中写明完整的路径。

### 2.3.3 Rstudio 常用命令

### 2.3.4 R 包介绍

- 包是 R 函数、数据、预编译代码以一种定义完善的格式组成的集合。
- 计算机上存储包的目录称为库 (library)。
- 函数.libPaths() 能够显示库所在的位置。

| 函数 | 功能 |
| --- | --- |
| getwd() | 显示当前的工作目录。 |
| setwd("new_path") | 修改当前的工作目录为new_path。 |
| ls() | 列出当前工作空间中的对象。 |
| rm(objectList) | 移除(删除)一个或多个对象。 |
| rm(list = ls()) | 移除当前工作空间的所有对象，即清除R工作空间中的内存变量。 |
| help(options) | 显示可用选项的说明。 |
| options() | 显示或设置当前选项。 |
| history(n) | 显示最近使用过的n个命令(默认值为25)。 |
| savehistory("myfile") | 保存命令历史到文件myfile中(默认值为.Rhistory)。 |
| loadhistory("myfile") | 载入一个命令历史文件(默认值为.Rhistory)。 |
| save.image("myfile") | 保存工作空间到文件myfile中(默认值为.RData)。 |
| save(objectlist,file="myfile") | 保存指定对象到一个文件中。 |
| load("myfile") | 读取一个工作空间到当前会话中(默认值为.RData)。 |
| q() | 退出R，并将会询问是否保存工作空间。 |

图 3: Rstudio 常用命令

- 函数 library() 则可以显示库中有哪些包。
- R 自带了一系列默认包 (包括 base、datasets、utils、grDevices、graphics、stats 以及 methods), 它们提供了种类繁多的默认函数和数据集。其他包可通过下载来进行安装。
- 使用命令 install.packages(“package_name”,“dir”) 即可。
- 查看包帮助：library(help=“package_name”)
- 加载包：library(package_name) 或者 require(package_name)

### 2.3.5 常用包

- 空间数据分析类
- 机器学习与统计学习类
- 多元统计类
- 药物动力学数据分析类
- 计量经济类
- 金融分析类

- 并行计算类
- 数据库访问类

## 2.4 作业

1. 下载安装 R 与 Rstudio，并正确设置界面。
2. 下载包，并使用包查看相关函数命令及数据集。

# 3 第三章 R 语言的基本概念和语法

教学目的：

1. 熟悉R语言对象的属性与分类；
2. 了解R语言各类对象的建立与存取；
3. 掌握R编程基础知识。

教学重难点：

1. 重点：掌握R编程基础知识；
2. 难点：掌握R软件的编程方法；

## 3.1 数据对象与数据读写

### 3.1.1 数据类型

基本赋值语句

```
x<-8
```

R 语言的对象常见的数据类型有：字符型、数值型、逻辑型、复数型。此外，也可能是缺省值 (NA)。

对于未知类型的对象，在 R 中有 3 个函数可以查看对象的类型:class、mode、typeof。
使用格式：class(x)

| 类型 | 辨别 | 转换 |
|---|---|---|
| character | is.character() | as.character() |
| complex | is. complex() | as. complex() |
| integer | is. integer() | as. integer() |
| logical | is. logical() | as. logical() |
| NA | is.na() | as.na() |
| numeric | is. numeric() | as. numeric() |

图 4: R 数据类型

其中 x 为需要查看类型的对象，mode、typeof 函数使用格式与 class 函数相同。

实例：创建 3 个不同类型的数据，展示 3 个辨别函数的区别。

```
df <- data.frame(c1 = letters[1:3], c2 = 1:3, c3 = c(1, -1, 3.0),
    stringsAsFactors = F)
sapply(df, mode)
```

```
##          c1          c2          c3
## "character"   "numeric"   "numeric"
```

```
sapply(df, class)
```

```
##          c1          c2          c3
## "character"   "integer"   "numeric"
```

```
sapply(df, typeof)
```

```
##          c1          c2          c3
## "character"   "integer"    "double"
```

在展现数据的细节上，mode<class<typeof。mode 函数只查看数据的大类，class 函数查看数据的类，typeof 函数则更加细化，查看数据的细类。

### 3.1.2 数据结构

R 拥有许多用于存储数据的对象类型，包括向量、矩阵、数组、数据框和列表。

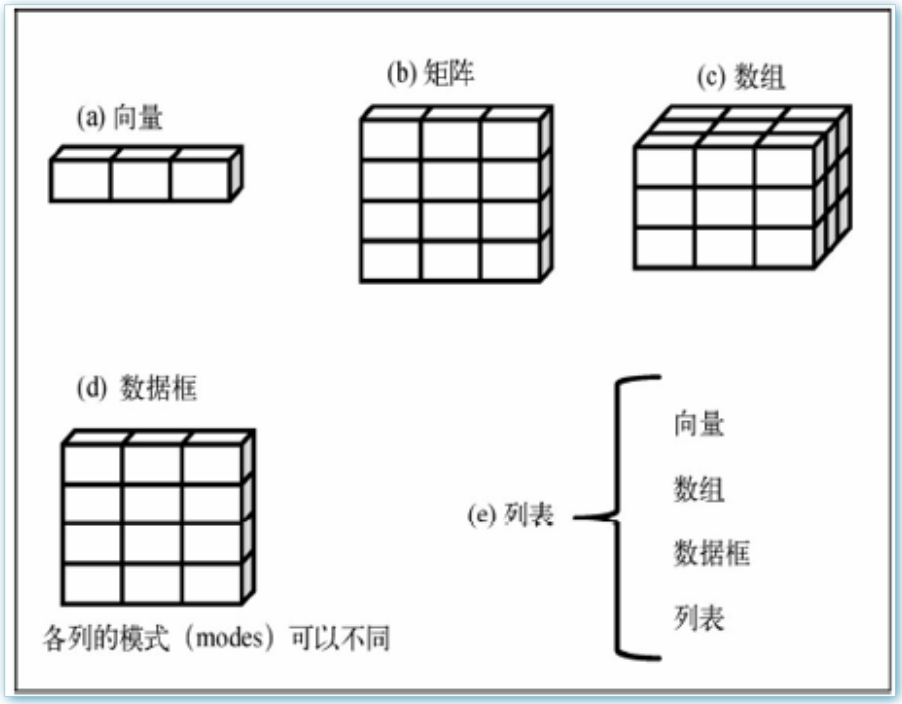


图 5: R 数据结构

1. 数据框 (data frame) 是 R 中用于存储数据的一种结构：列表示变量，行表示观测。
在同一个数据框中可以存储不同类型 (如数值型、字符型) 的变量。
2. 向量是以一维数组的方法管理数据的一种对象类型。可以说向量是 R 语言中最基本的数据类型，很多算法函数都是以向量的形式输入的。
向量可以是数值型、字符型、逻辑值型 (T、F) 和复数型。

```
x1 <- c(1, 2, 3, 4)  # 创建数值型向量，可写成 x1=c(1:4)
x2 <- c("a", "b", "c", "d")  # 创建字符型变量
x3 <- c(TRUE, FALSE, FALSE, TRUE)  # 创建逻辑型变量
```

字符型、逻辑值型 (T、F)、数值型和复数型；
一个向量的所有元素都必须属于相同的类型。如果不是，R 将强制执行类型转换。
3.R 语言最强大的方面之一就是函数的向量化。

```
w<-seq(1:10)
x<-sqrt(w)
tow_number<-w+x
```

提问：如果两个向量长度不同，能相加吗？
4. 特殊向量的创建

- seq(1:n:m)
- req(x,n) 5. 索引向量
  只要访问向量中的部分或个别元素。这就是所谓的索引，它用方括号 [] 来实现。

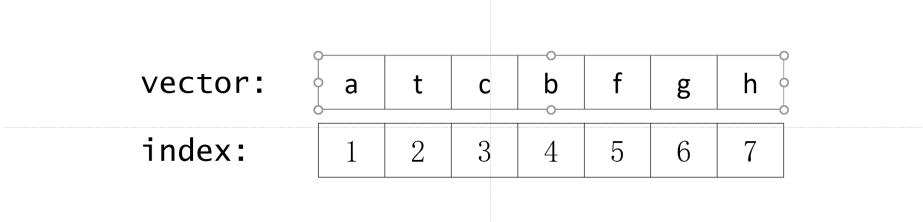


图 6: 向量索引

R 语言中，提供如下多种索引方法。

- 给向量传入正数，它会返回此位置上的向量元素切片。它的第一个位置是 1（而不像其他某些语言一样是 0）。
- 给向量传入负数，它会返回一个向量切片，它将包含除了这些位置以外的所有元素。
- 给向量传入一个逻辑向量，它会返回一个向量切片，里面只包含索引为 TRUE 的元素。
- 对于已命名的向量，给向量传入命名的字符向量，将会返回向量中包含这些名字的元素切片。

另外，还可以通过掩码方式进行操作：

- which 函数将返回逻辑向量中为 TRUE 的位置。R 语言可以对已经创建好的向量直接进行元素扩展及删除等编辑操作。
  向量中元素的删除通过减号加元素下标的形式实现。

向量排序（sort 函数)

| 常用参数 | 参数描述 | 选项 |
| --- | --- | --- |
| x | 排序的对象 | 排序的对象为数值型，也可以是字符型。 |
| decreasing | 排序的顺序 | 默认设置为FALSE，即升序排序。设置为TRUE时，为降序排序。 |
| na.last | 是否将缺失值放到序列的最末尾。 | 默认设置为FALSE，设置为TRUE时将向量中的NA值放到序列的最末尾。 |

图 7: 向量排序

6. 矩阵和数组
利用矩阵 matrix 可以描述二维数据，和向量相似，其内部元素可以是实数、复数、字符、逻辑型数据。
矩阵 matrix 使用两个下标来访问元素，A[i,j] 表示矩阵 A 第 i 行、第 j 列的元素。
多维数组 array 可以描述多维数据。array 有一个特征属性叫维数向量（dim 属性），
它的长度是多维数组的维数，dim 内的元素则是对应维度的长度。
矩阵是数组的特殊情况，它具有两个维度。

**矩阵的合并**

- cbind 函数把其自变量横向拼成一个大矩阵，rbind 函数把其自变量纵向拼成一个大矩阵。
- cbind 函数的自变量是矩阵或看作列向量的向量时，自变量的高度（行数）应该相等。

矩阵的拉直
设 A 是一个矩阵，则函数 as.vector(A) 可以将矩阵转化为向量。

```
A <- matrix(1:6,2,3)
AA<-as.vector(A)
```

矩阵的行或列计算的函数

- colSums 对矩阵各列求和
- colMeans 求矩阵各列的均值
- rowSums 对矩阵各行求和
- rowMeans 求矩阵各列的均值

矩阵运算函数：

| 函数 | 功能 |
| --- | --- |
| +-*/ | 四则运算，要求矩阵的维数相同，对对应位置的各元素进行运算 |
| colSums() | 对矩阵的各列求和 |
| rowSums() | 对矩阵的各行求和 |
| colMeans() | 对矩阵的各列求均值 |
| rowMeans() | 对矩阵的各行求均值 |
| t() | 对矩阵的行列进行转置 |
| det() | 求解方阵的行列式 |
| outer() | 求解矩阵的外积（叉积） |
| %*% | 矩阵乘法，要求第一个矩阵的列数与第二个矩阵的行数相同 |
| diag() | 对矩阵取对角元素，若对象为向量，则生成以向量为对角元素的对角矩阵 |
| solve() | 对矩阵求解逆矩阵，要求矩阵可逆 |

图 8: 矩阵运算

**数组创建**

数组是矩阵的扩展，它把数据的维度扩展到两个以上。可以通过 array 函数方便地创建数组。

- 对于矩阵和数组，dim 函数将返回其维度的整数值向量。
- 对于矩阵，函数 nrow 和 ncol 将分别返回行数和列数。

**列表和数据框**

列表 list 和数据框 data.frame 也是一个二维数据。在使用 R 语言进行数据分析和挖掘的过程中，向量和数据框的使用频率是最高的，list 则在存储较复杂的数据时作为数据对象类型。

**数据框创建**

data.frame 函数可以直接把多个向量建立为一个数据框，并为列设置名称。

```
my.datasheet <- data.frame(site = c('A','B','A','A','B'),
+season = c('winter','summer','summer','spring','fall'),
+pH = c(7.4,6.3,8.6,7.2,8.9))
```

```
names(my.datasheet)
names(my.datasheet)
```

可以通过 names() 来读取并编辑列名称。

**数据框索引**通过 [行下标, ]，可以直接获取相应行的所有元素，并以数据框对象形式返回。**列表创建**

```
(my.list <- list(stud.id = 34453,
+                  stud.name = '张三',
+                  stud.marks = c(14.3,12,15,19)))
$stud.name
$stud.marks
```

### 3.1.3 数据读写

R 暂时没有很好用的可视化的数据导入工具，所有需要使用命令来导入导出数据。
如果使用 Rstudio 编辑器，可以使用其提供的简单的数据导入功能。
使用它可以从 txt、csv 等文本格式的文件或者从网络中获取数据。
（使用软件进行演示）

1. CSV 文件读取
   library(learningr)
   deer_file <- system.file('extdata','RedDeerEndocranialvolume.dlm',package ='learningr')
   deer_data <- read.table(deer_file,header = TRUE,fill = TRUE)
   head(deer_data)

2. 在 Windows 系统中，可以使用 RODBC 包来访问 Excel 文件，或直接用 xlsx 包和 XLConnect 包来访问 Excel2007 文件.
   其他的数据类型读取，不作介绍，大家可以 help 相关函数与包。

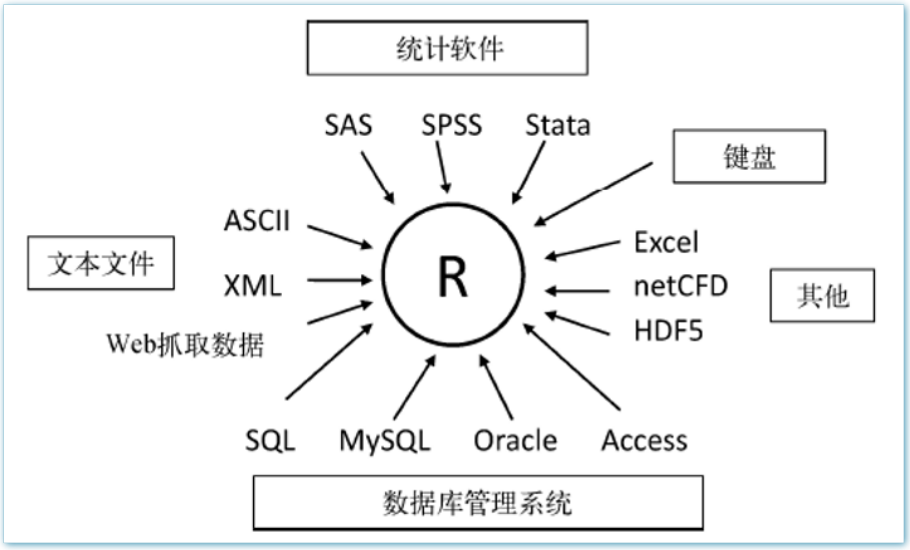


图 9: 数据源读取类型

#### 3.1.4 作业

要求学生自行下载一只股票的数据，然后利用 R 软件读取数据，并保存。

## 3.2 数据集的基本处理

1. 访问数据框变量

```
data.iris <- data.frame(Sepal.Length = c(5.1, 4.9, 4.7, 4.6),
Sepal.Width = c(3.5, 3.0, 3.2, 3.1),
Petal.Length = c(1.4, 1.4, 1.3, 1.5), Pe.tal.Width = rep(0.2, 4))
data.iris[, 1]  # 索引第一列
data.iris$Sepal.Length  # 按列的名称索引
data.iris[1:3, ]  # 索引第一至三行
subset(data.iris, Sepal.Length < 5)  # 按条件索引行
data.iris["Sepal.Length"][1]  # 索引Sepal.Length列第一个元素
```

2. 如何创建新变量?

```
mydata <- data.frame(x1 = c(2, 2, 6, 4), x2 = c(3, 4, 2, 8))
# 创建新变量方法一
mydata$sumx <- mydata$x1 + mydata$x2
mydata$meanx <- (mydata$x1 + mydata$x2) / 2
# 创建新变量方法二
mydata <- transform(mydata, sumx = x1 + x2, meanx = (x1 + x2) / 2)
```

3. 修改变量名
交互式编辑器修改变量名
(软件演示操作)

### 3.2.1 数据属性列增加

1. 变量的重命名
R 修改变量名的方式有很多种，常用 rename 函数，names 函数，colnames 和 rownames 等函数实现对变量名字的修改。

**rename 函数**

reshape 包中有一个 rename 函数，可用于修改数据框和列表的变量名，但不能用于修改矩阵的变量名。
使用格式：
rename(dataframe, c(oldname = “newname”, oldname = “newname”, …))
names() 函数和 rename() 函数一样，可修改数据框和列表的变量名，而不能用于修改矩阵的变量名，不同点在于，
names() 函数会在原数据集中修改变量名，但 rename() 函数并不会直接改变原数据集中的变量名。
使用格式：
names(x) <- value
2. 属性列增加
colnames() 函数和 rownames() 函数
rownames() 和 colnames() 函数可修改矩阵行名和列名，同时，也能够修改数据框的行名和列名。
使用格式：
rownames(x) <- value
rownames(x) <- value

### 3.2.2 清洗数据

**缺失值分析**

在 R 中，缺失值以符号 NA（Not Available，不可用）表示。不可能出现的值（例如，被 0 除的结果）通过符号 NaN（Not a Number，非数值）来表示。与 SAS 等程序不同，R 中字符型和数值型数据使用的缺失值符号是相同的。

| 函数 | 描述 |
| --- | --- |
| is.na(x) | 返回一个与x等长的逻辑向量，并且由相应位置的元素是否是NA来决定这个逻辑向量相应位置的元素是TRUE还是FALSE。TRUE表示该位置的元素是缺失值。 |
| anyNA(x, recursive = FALSE) | 判断数据中是否存在缺失值，返回TRUE或FALSE值。若存在缺失值则返回TRUE，否则返回FALSE。 |
| na.omit(x) | 删除含有缺失值的观测 |
| complete.cases(x) | 返回一个逻辑向量，不存在缺失值的行的值为TRUE，存在缺失值的行的值为FALSE。 |

图 10: 缺失值处理

complete.cases 检查哪行有缺失值。
na.omit 能删除数据框中所有带缺失值的行

**处理日期变量**

日期值通常以字符串的形式传入 R 中，然后转化为以数值形式存储的日期变量。在 R 中，
字符型的日期值无法进行日期变量的计算，因此可通过日期值处理函数，将字符型的日期值转换成日期变量。

**日期格式**

（利用软件演示操作）

**处理日期变量**

R 软件处理日期函数主要有两个：strptime,strftime
x <- strptime(x, “%Y-%m-%d %H:%M:%S”) % 用于输入数据 strftime(x, format = “%Y/%m/%d”) % 用于输出数据
format(x,“%d/%m/%Y”)，% 输出的格式转换成 format 定义的格式

**数据排序**

R 中涉及排序的基本函数有 order、sort 和 rank 三个。下面看下其基本用

| 函数 | 功能 |
| --- | --- |
| Sys.Date | 返回系统当前的日期。 |
| Sys.time | 返回系统当前的日期和时间。 |
| date | 返回系统当前的日期和时间（返回的值为字符串）。 |
| as.Date | 将字符串形式的日期值转换为日期变量。 |
| as.POSIXlt | 将字符串转化为包含时间及时区的日期变量。 |
| strptime | 将字符型变量转化为包含时间的日期变量。 |
| strftime | 将日期变量转换成指定格式的字符型变量。 |
| format | 将日期变量转换成指定格式的字符串。 |

图 11: 日期数据处理

| 符号 | 含义 | 示例 |
| --- | --- | --- |
| %d | 数字表示的日期（00~31） | 01~31 |
| %a | 缩写的星期名 | Mon |
| %A | 非缩写的星期名 | Monday |
| %w | 数字表示的星期天数 | 0-6，周日为0 |
| %m | 数字表示的月份（00~12） | 00~12 |
| %b | 缩写的月份 | Jan |
| %B | 非缩写的月份 | January |
| %y | 二位数的年份 | 16 |
| %Y | 四位数的年份 | 2016 |
| %H | 24小时制小时 | 00-23 |
| %I | 12小时制小时 | 01-12 |
| %p | AM/PM指示 | AM/PM |
| %M | 十进制的分钟 | 00-60 |
| %S | 十进制的秒 | 00-60 |

图 12: 日期格式

法：

- sort(x, decreasing = FALSE, …)
- order(…, na.last = TRUE, decreasing = FALSE)
- rank(x, na.last = TRUE, ties.method = c("average", "first", "random", "max", "min")) 演示列子：

```
x <- c(19, 84, 64, 2)
order(x)
```

```
## [1] 4 1 3 2
```

```
rank(x)
```

```
## [1] 2 4 3 1
```

```
sort(x)
```

```
## [1]  2 19 64 84
```

(利用列子说明三者的区别)

### 3.2.3 选取变量及数据

**合并数据集**

数据框的编辑可以通过 rbind 和 cbind 函数。需要注意的是，使用 rbind 和 cbind 函数对于数据框而言，

分别为增加新的样本数据和增加新属性变量。

rbind 的自变量的宽度（列数）应该与原数据框的宽度相等，cbind 的自变量的高度（行数）应该与原数据框的高度相等。

**选取变量及数据**

删除向量中的变量

vector <- c(1, 2, 3, 4)

vector[-1] % 删除第一个元素

使用 subset 函数选取数据

subset 函数是一种较为简便的方法用来选取变量与观测变量，功能为选取变量与观测变量.

代码：

```
df1 <- data.frame(name = c("aa", "bb", "cc"), age = c(20, 29, 30),
                  sex = c("f", "m", "f"))
selectresult1 <- subset(df1, name == "aa", select = c(age, sex))
selectresult2 <- subset(df1, name == "aa" & sex == "f", select = c(age, sex))
```

**随机抽样**

简单随机抽样可通过 srswr 函数，srswor 和 sample 函数实现。srswr 函数和 srswor 函数在 sampling 包中，

使用前需要先加载 sampling 包。下面看下其基本用法：

srswr(n, N)

srswor(n, N)

sample(x, size, replace = FALSE, prob = NULL)

### 3.2.4 整合数据

使用 SQL 语句操作数据:

name<-c(rep(“张三”, 1, 3), rep(“李四”, 3))

subject<-c(“数学”, “语文”, “英语”, “数学”, “语文”, “英语”)

score<-c(89, 80, 70, 90, 70, 80)

stuid<-c(1, 1, 1, 2, 2, 2)

stuscore<-data.frame(name, subject, score, stuid)

library(sqldf)

% 计算每个人的总成绩并排名 (要求显示字段：姓名，总成绩)

sqldf(”select name, sum(score) as allscore from stuscore group by name order

**数据汇总统计**

使用格式：aggregate(x, by, FUN)

粘贴数据结构——R 中合并两个数据集可以通过专门的函数 merge( ) 来实现。

在 R 中，数据融合通过 reshape2 包中的 melt() 函数实现。

使用格式：

melt(data, varnames, value.name = “value”, na.rm = FALSE)

**数据重塑**

melt 获得的数据可以用 acast 或 dcast 还原。acast 获得数组，dcast 获得数据框。

使用格式：

cast(data, formula, fun.aggregate = NULL,…)

### 3.2.5 处理字符数据

正则表达式是用于描述或匹配一个文本集合的表达式。所有英文字母、数字和

很多可显示的字符本身就是正则表达式，用于匹配它们自己。

| 符号 | 描述 |
|---|---|
| . | 除了换行以外的任意字符 |
| \\ | 转义字符，如要匹配括号就要写成 "\\(\\)" |
| \| | 表示可选项，即 \| 前后的表达式任选一个。 |
| ^ | 放在表达式开始出表示匹配文本开始位置，<br>放在方括号内开始处表示非方括号内的任一字符 |
| $ | 放在句尾，表示一行字符串的结束 |
| ( ) | 提取匹配的字符串，(\\s*)表示连续空格的字符串 |
| [ ] | 选择方括号中的任意一个（如[a-z] 表示任意一个小写字符） |
| { } | 前面的字符或表达式的重复次数。<br>如{5,12}表示重复的次数不能少于5次，不能多于12次，否则都不匹配。 |
| * | 前面的字符或表达式重复零次或更多次 |
| + | 前面的字符或表达式重复一次或更多次 |
| ? | 前面的字符或表达式重复零次或一次 |

图 13: 常用字符串式

常用的字符串处理函数:

（利用软件演示正则条件处理函数）学生练习

| 函数 | 描述 |
| --- | --- |
| nchar(x) | 计算x中的字符数量 |
| substr(x, start, stop) | 提取或替换一个字符向量中的子串 |
| grep(pattern, x, ignore.case = FALSE, perl = FALSE, value = FALSE, fixed = FALSE, useBytes = FALSE, invert = FALSE) | 字符串查询，返回结果为匹配项的下标。 |
| sub(pattern, replacement, x, ignore.case = FALSE, fixed=FALSE) | 对第一个满足条件的匹配做替换，原字符串并没有改变，要改变原变量只能通过再赋值的方式。 |
| gsub(pattern, replacement, x, ignore.case = FALSE, perl = FALSE, fixed = FALSE, useBytes = FALSE) | 把所有满足条件的匹配都做替换，原字符串并没有改变，要改变原变量只能通过再赋值的方式。 |
| strsplit(x, split, fixed = FALSE, perl = FALSE, useBytes = FALSE) | 在split处分割字符向量x中的元素。 |
| paste (..., sep = " ", collapse = NULL) | 连接字符串，分隔符为sep |

图 14: 字符串处理函数

## 3.3 函数与控制流

### 3.3.1 常用函数处理数据

和其它数据分析软件一样，在 R 语言中，也有许许多多可应用于数值计算和统计分析的数值函数，
主要可以分成数学函数，统计函数和概率函数三大类。（利用 PPT 简单讲解）
1.apply 家族
apply 包括 apply、lapply、tapply、sapply、vapply、mapply 等几个函数，这些函数都能够
把函数按照某种方式运用于数据。
这些函数的使用方法为：

- apply(x, MARGIN, FUN, ...) # 把 FUN 函数运用到 x 数据的第 MARGIN 维度上
- lapply(x, FUN, ...) # 把函数 FUN 运用到列表的每一个元素
- tapply(x, INDEX, FUN=NULL, ..., simplify=TRUE) # 把 FUN 函数根据 INDEX 索引应用到 x 数据
- sapply(x, FUN, ..., simplify=TRUE, USE.NAMES=TRUE)
  % 是 lapply 函数更加友好的版本，可以使用 simplify 参数来调整输出的数据格式
- vapply(x, FUN, FUN.VALUE, ..., USE.NAMES=TRUE) % 类似于 sapply，但是返回值只能按照预先制定的方式输出

- mapply(FUN, ..., MoreArgs = NULL, SIMPLIFY = TRUE, USE.NAMES = TRUE) # 运用于多变量情况（利用软件演示 apply 函数示例）

### 3.3.2 编写条件分支语句

### 3.3.3 编写循环语句

1.if/else 判断语句
在 R 语言中创建 if-else 语句的基本语法如下所示。

```
if (boolean expression) {
    // statement(s) will execute if the boolean expression is true.
} else {
    // statement(s) will execute if the boolean expression is false.
}
```

if/else 判断语句

例子：if 语句

```
# if-else 语句
x <- c("what","is","truth")
if ("Truth" %in% x) {
  print("Truth is found")
} else {
  print("Truth is not found")
}
```

```
## [1] "Truth is not found"
```

该语句可以实现多重条件的嵌套，三重嵌套的条件语句的基本语法如下所示。

```
if (boolean_expression 1) {
     // Executes when the boolean expression 1 is true.
```

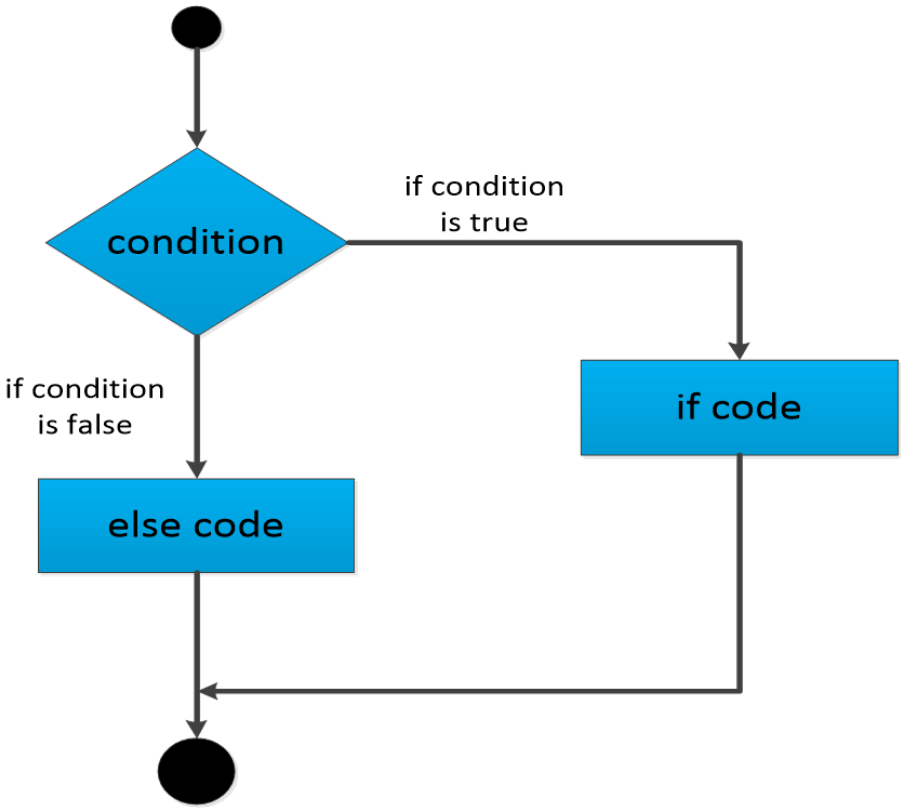
condition
if condition
is true
if code
if condition
is false
else code

图 15: if 语句

```
} else if ( boolean_expression 2) {
    // Executes when the boolean expression 2 is true.
} else if ( boolean_expression 3) {
    // Executes when the boolean expression 3 is true.
} else {
    // executes when none of the above condition is true.
```

2.switch 分支语句
switch 分支语句的使用格式如下:
switch(expression,list)
3.for 循环语句
使用格式如下:
for (name in expr1) {expr2}
在循环过程中，若需要输出每次循环的结果，可使用 cat 函数或 print 函数，接下来将介绍 cat 函数的使用方法.
使用格式如下：
cat(expr1,expr2,…)
3.while 循环语句
使用格式如下：
while (cond) {expr}
4.repeat-break 循环语句
使用格式如下：
repeat expr 或者 repeat {if(cond){break}}

### 3.3.4 编写自定义函数

一个函数的结构大致如下所示。

```
myfunction <- function(arglist) {
    statements
    return(object)
}
```

函数体通常包括三个部分，异常处理、运算过程和返回值.

- 异常处理：输入的数据不能满足函数计算的要求，或者类型不符，这时应设计相应的机制提示哪个地方出现错误。
- 运算过程：包括具体的运算步骤。运算过程和该函数要完成的功能有关。
- 返回值：用 return 函数给出，返回对象的数据类型是任意的，从标量到列表皆可。函数在内部处理过程中，
  一旦遇到 return，就会终止运行，将 return 内的数据作为函数处理的结果给出。

## 3.4 绘制基本图形

### 3.4.1 绘制基础图形

分析数据第一件要做的事情就是观察它。对于每个变量需要注意的是最常见的值，值域，不寻常的观测，
多个变量的关系，是否符合模型假设等。对数据进行可视化就显的很重要.

| 函数 | 图形 | 功能 |
|---|---|---|
| hist | 直方图 | 分布 |
| sm.density.compare | 密度图 | 分布 |
| boxplot | 箱线图 | 分布 |
| vioplot | 小提琴图 | 分布 |
| barplot | 条形图 | 分布 |
| dotchart | Cleveland点图 | 分布 |
| pie | 饼图 | 分布 |
| plot | 根据作图对象而异，最简单的是散点图 | 关系（对散点图），图形不同功能不同 |
| pairs | 散点图矩阵 | 关系 |
| corrgram | 相关图 | 关系 |

图 16: 画图函数

| | | |
|---|---|---|
| qqplot | QQ图 | 假设检验 |
| mosaicplot | 马赛克图 | 假设检验 |
| stars | 星状图 | 突出特征 |
| sunflowerplot | 向日葵散点图 | 突出特征 |
| contour | 等高图 | 聚类 |
| heatmap | 热图 | 聚类 |

图 17: 画图函数

1. 直方图
在 R 中，hist 函数可用于绘制直方图，显示连续数据的分布情形。hist 函数的具体用法如下所示。
hist(x,breaks= ,freq=,…)
2. 条形图
在 R 中，可以使用 barplot 函数绘制条形图，展示各类数据的数量分布情形。条形图的 x 轴是数据类别，
y 轴是相应类别的频数。barplot 函数的具体用法如下所示。
barplot(height, beside =, horiz =, , …)
3. 饼图
R 语言里，提供的绘制饼图函数为 pie 函数，其具体用法如下所示。
pie(x, labels = names(x), radius = 0.8,…)
4. 箱线图
R 中，boxplot 函数用于绘制箱型图。单独的箱线图的使用格式如下所示。boxplot(x,…,range=,width=,varwidth=,notch=,names=,horizontal=,add=FALSE,…)
5. 散点图
在 R 语言中，绘制散点图的函数是 plot 函数，其具体用法如下所示。
plot(x, y, …)
6. 多变量相关矩阵图
在 R 的 corrgram 包中的 corrgram 函数可绘制多变量相关矩阵图。使用格

式如下所示。

corrgram(x,order=, lower.panel= , upper.panel=,text.panel=,diag.panel=,...)

7. 核密度图

sm.density.compare 函数可以直接堆放多条密度曲线。使用格式如下。

corrgram(x,order=, lower.panel= , upper.panel=,text.panel=,diag.panel=,...)

8.QQ 图

QQ 图的原理是如果一批数据服从某种理论分布，看其经验分布和理论分布是否一致。将排序后的数据

和理论分布的分位数进行比较后大致相等，说明了经验分布和理论分布相似。

使用格式如下：

qqplot(x, y„...); qqnorm(y,...);qqline(y)

（利用实际数据演示）

### 3.4.2 修改图形参数

1. 修改颜色

- R 语言提供了自带的固定种类的颜色，主要涉及的是 colors 函数

- 通过 palette 函数固定调色板，只要设定好了调色板，它的取值就不会再改变（直到下一次重新设定调色板）。2. 线条样式

| 函数 | 说明 | 使用格式 |
|---|---|---|
| lines | 在画布中添加曲线，可以设置的参数包括：线条样式（lty）、颜色（col）、粗细（lwd）等 | lines(x, lty = , lwd = ,...) |
| abline | 在画布中添加参考线，可以设置的参数包括：直线的截距（a）、直线的斜率（b）、水平线的纵轴值（h）、垂直线的横轴值（v）等 | abline(a = NULL, b = NULL, h = NULL, v = NULL, reg = NULL, lty = , lwd = ,...) |
| segments | 两点之间绘制线段，绘制对象是两端点的坐标 | segments(x0, y0, x1, y1, lty = , lwd = ,...) |
| arrows | 在线段端点加上箭头，箭头与线段之间的夹角（angle）可调 | arrows(x0, y0, x1, y1, angle = , lty = , lwd = ,...) |
| grid | 在绘图的基础上添加网格线，其中ny用户设置水平网格的数目，nx用于设置垂直网格的数据。equilogs是当坐标取了对数之后，是否仍使用等距的网格线 | grid(nx = NULL, ny = nx, col =, lty =, lwd =, equilogs = TRUE) |
| rug | x为坐标轴须的位置；ticksize为坐标轴须的长度；side为坐标轴须的位置，默认值1为x轴，取值2时为y轴 | rug(x, ticksize =, side =, col =, lty =, lwd =, ...) |

图 18: 线条样式

3. 修改文本属性

title 函数，text 函数和 mtext 函数可以在打开的画布上添加文字元素，其中 title 函数是在图形上添加标题元素，

text 函数可以在图形中任意位置添加文本，mtext 函数则是对图形的四条边上添加文本。

| 函数 | 说明 | 使用格式 |
|---|---|---|
| title | 添加标题元素，其中main是主标题，sub是副标题，xlab是x轴标题，ylab是y轴标题，选项都是一个列表list(text, font=, col=, cex=,...)或者简单的text，text是文本内容 | title(main = NULL, sub = NULL, xlab = NULL, ylab = NULL, line = NA, outer = FALSE,...) |
| text | 在图形中任意位置添加文本，其中x, y 确定标签位置，labels是文本内容 | text(x, y = NULL, labels = seq_along(x), cex = 1, col = NULL, font = NULL,...) |
| mtext | 在图形的四条边上添加文本，其中text与labels一样指文字的内容，side取值为整数1~4分别把周边文本作在表示图形的下、左、上、右边。line设置一个距离图形边缘的行数 | mtext(text, side = 3, line=0, cex = NA, col = NA, font = NA, ...) |

图 19: 文本属性

4. 设置坐标轴

绘图函数中，设置坐标轴展示和范围的参数

| 参数 | 描述 |
|---|---|
| axes | 逻辑参数，如果axes=TRUE（默认），则显示坐标轴，如果axes=FALSE，则隐藏坐标轴。 |
| xaxt/yaxt | 坐标轴样式，默认值”s”，表示x /y轴以标准样式显示，取值”n”表示隐藏x /y轴 |
| xaxs/yaxs | 坐标轴计算方式，默认值”r”表示把原始数据的范围向外扩大4%，作为x /y轴范围，取值”l”表示x /y轴范围为原始数据范围 |
| xlim/ylim | 坐标轴范围，设置为c(from,to) , from是x /y轴的首坐标,to是尾坐标 |

图 20: 设置坐标轴

axis 函数来创建自定义的坐标轴

axis 函数绘图例子：

| 参数名称 | 参数解释 |
| --- | --- |
| side | 坐标轴所在的边，1,2,3,4分别表示下，左，上，右 |
| at | 通过向量来设置坐标轴内各刻度标记的位置，at参数要与labels向量一一对应 |
| labels | 一个向量字符，表示坐标轴各刻度的名称（刻度标记），labels参数要与at向量一一对应 |
| font.axis | 刻度标记的字体，1（默认）为正常字体，2表示粗体，3表示斜体，4表示粗斜体。 |
| cex.axis | 刻度标记的大小，1（默认）表示正常大小，小于1表示缩放，大于1表示放大 |
| col.axis | 刻度标记的颜色，对应颜色名称即可 |
| tick | 设置是否画出坐标轴，为TRUE（默认）时，表示画出坐标轴，为FALSE时则不画出，此时并不影响刻度标记labels的展示 |

图 21: 坐标轴刻度

```
plot(c(1:12), col="white", xaxt="n", yaxt="n", ann = FALSE)
axis(1, at=1:12, col.axis="red", labels=month.abb)
axis(2, at=seq(1,12,length=10), col.axis="red", labels=1:10, las=2)
axis(3, at=seq(1,12,length=7), col.axis="blue", cex.axis=0.7, tck=-0.01,
labels = c("Mon", "Tues", "Wed", "Thu", "Fri", "Sat", "Sun"))
axis(4, at=seq(1,12,length=11), col.axis="blue", cex.axis=0.7, tck=-0.01,
labels=seq(0, 1, 0.1), las=2)
```

5. 添加图例

legend 函数的具体用法如下所示:

legend(x, y = NULL, legend, col = par(“col”), lty, pch, bty = “o”,
bg = par(“bg”), ncol = 1, horiz=FALSE, xpd = FALSE, title = NULL)

legend 函数参数:

图例位置设置:

### 3.4.3 保存图形

R 语言提供将图片输出到屏幕的 windows 函数和 X11 函数，其中 windows 函数用于 Windows 系统，

| 参数名称 | 参数解释 |
|---|---|
| x, y | 设置图例的位置（默认左上角位置），除使用x和y参数外，也可以使用字符"bottomright", "bottom", "bottomleft", "left", "topleft", "top", "topright", "right", "center" |
| legend | 一个字符向量，表示图例中的文字 |
| horiz | 图例的排列方式，为FALSE（默认）时，图例垂直排列，为TRUE时，图例水平排列 |
| ncol | 图例的列数目，当horiz=TRUE时，该项无意义 |
| pch | 图例中点的样式，可取0-25，其中0-14为空心点，15-25为实心点；也可以直接通过pch="+"的方式定义点的样式。 |
| lty | 图例中线的样式，0表示不画线，1表示实线，2表示虚线，3表示点线 |
| col | 图例中点和线的颜色，令col等于对应颜色名称即可 |
| bg | 图例的背景颜色，令bg等于对应颜色名称即可。在bty参数为"n"时无效 |
| bty | 设置图例框的样式，取"o"（默认）时表示显示边框，取"n"时表示无边框 |
| xpd | 是否在作图区域外作图,默认FALSE，即不允许在作图区域外作图 |
| title | 设定图例的标题 |

图 22: 图例设置

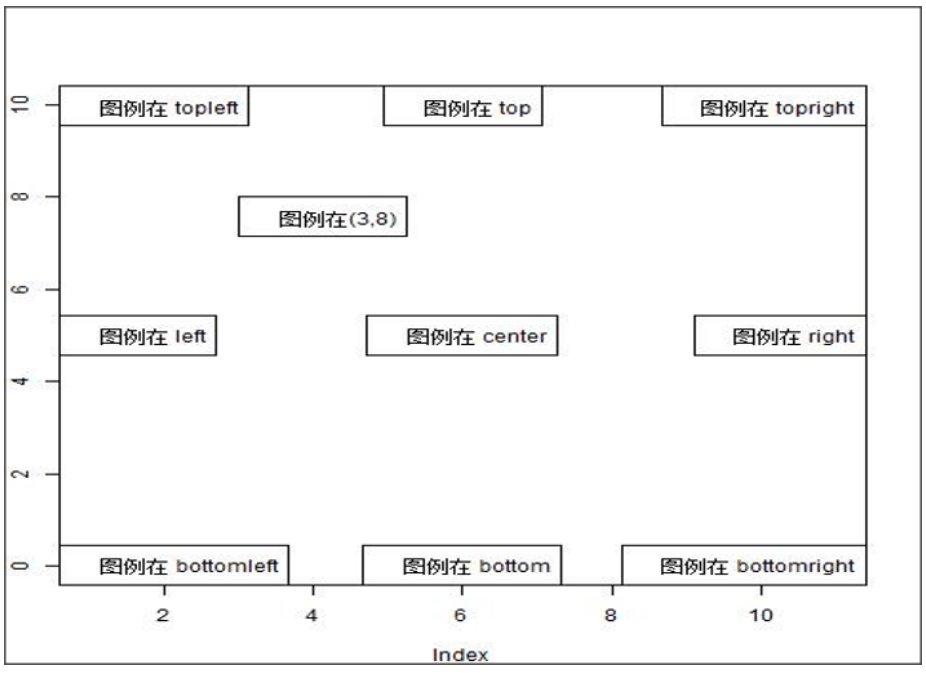


图 23: 图例位置设置

X11 函数用 UNIX 类型的系统的 X11 桌面系统。
windows() % 打开图形设备界面，UNIX 用 X11()
plot(iris) % 在打开的图形界面绘制散点矩阵图
选择 “文件” 菜单下的 “另存为” 可将图片以不同的文件形式输出到屏幕。

```
#保存为jpg格式
jpeg(filenames = 'C:\\Users\\45543\\Desktop\\iris.jpg')  # 保存的路径及文件名称、类型
plot(iris[, 1:4])  # 绘制图形
dev.off()  # 关闭关联
```

如果希望将当前画布的图形保存到指定路径，可以使用 win.metafile 函数，
bmp 函数，tiff 函数，
svg 函数，postscript 函数，png 函数，jpeg 函数等将接下来的图形绘制到
指定文件，并用 dev.off 函数结束关联。

### 3.4.4 作业

要求完成 7 种图的绘制，并对图进行正确设置坐标轴、刻度、图例等。

## 3.5 高级绘图

### 3.5.1 使用 lattice 包绘图

lattice 是由 Deepayan Sarkar 基于 grid 包的一套统计图形系统，它的图形
设计理念来自于 Cleveland 的 Trellis 图形。
lattice 包通过栅栏（trellis）图形来对多元变量关系进行直观展示，为单变
量和多变量数据
的可视化提供了一个全面的图形系统。一些用标准绘图很难实功能，lattice
却能很轻易地实现。
以 mtcars 数据集为例，绘制车身重量（wt）与每加仑汽油行驶的英里数
（mpg）的散点图。

```
library('lattice')
xyplot(wt ~ mpg, data = mtcars, xlab = 'Weight', ylab = 'Miles per Gallon',
```

```
main ='lattice包绘制散点图')
```

1. 图形参数

- 可使用 trellis.par.get 函数获取参数列表，trellis.par.set 函数则可以修改参数列表
- names(trellis.par.get()) # 查看参数列表的名称
- show.settings() # 图形化显示所有参数
- lattice 图形参数是有层次的，可以将它们看作列表的列表，即可使用 $ 对相关图形参数进行索引。
- 在 lattice 包，默认以不同颜色去区分不同类别数据。lattice 包中，可以通过管道符号（|）来添加条件变量 v，其表达方式如下所示。
  graph_function(formula|v,data=,options)
  例子：以 iris 数据集为例，以 Species（鸢尾花种类）为条件变量绘制 Sepal.Length（花萼长度）
  与 Sepal.Width（花萼宽度）的散点图。

```
library(lattice)
attach(iris)
xyplot(Sepal.Length ~ Sepal.Width | Species)
```

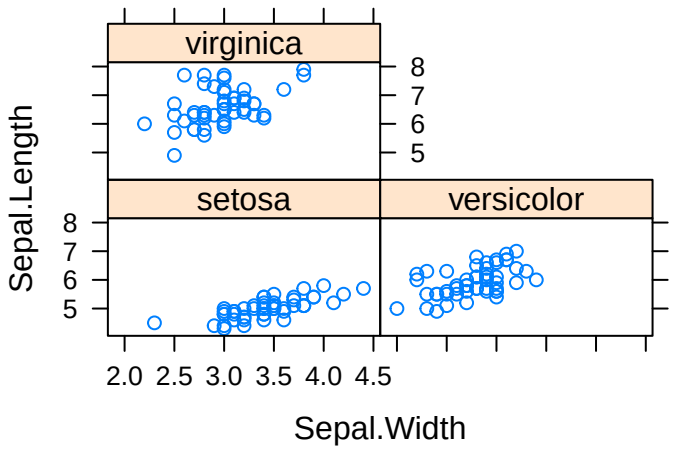

```
detach(iris)
```

2. 条件变量

- 在栅栏图形中，单个面板要依据条件变量的各个水平来创建。
- 设小写字母（x，y）代表数值型变量，大写字母（A，B）代表类别型变量（因子），在高级绘图函数中，表达式形式通常如下所示:x ~ y | A + B
- 竖线左边的变量为主要变量，右边的变量为条件变量。主要变量将变量映射到每个面板的坐标轴上。3. 面板函数在 lattice 包中，每个高级绘图函数都调用了一个默认的函数来绘制面板。默认函数：panel.graph_function
  面板函数参数：

| 函数 | 描述 |
| --- | --- |
| panel.abline | 在面板的图表区域增加线 |
| panel.curve | 在面板的图表区域增加曲线 |
| panel.rug | 在面板上增加轴须 |
| panel.mathdensity | 给定分布函数，绘制概率分布图 |
| panel.average | 按照因子变量，绘制平均值 |
| panel.fill | 对面板填充具体的颜色 |
| panel.grid | 绘制网格线 |
| panel.loess | 增加一条光滑曲线 |
| panel.lmline | 为数据增加一条回归线 |
| panel.refline | 在面板的图表区增加一条线 |
| panel.qqmathline | 在样本和理论分布的25分位点和75分位点加一条线 |
| panel.violin | 绘制小提琴图，通常用于箱线图 |

图 24: 面板函数参数

使用 xyplot 函数绘制的散点图上添加回归线，光滑曲线，轴须和网格线，只需要将 panel
参数设置为一个整合了多个面板函数的函数即可。

```
library('lattice')
my_panel<- function(x,y){panel.lmline(x, y, col = "red", lwd = 1,
                                      lty = 2)  # 为数据增加一条回归线
panel.loess(x,y)  # 增加一条光滑曲线
panel.grid(h = -1, v = -1)  # 绘制网格线
```

```
panel.rug(x, y)  # 在面板上增加轴须
panel.xyplot(x, y)}  # 绘制散点图
xyplot(mpg ~ wt, data = mtcars, xlab = "Weight", ylab = "Miles per Gallon",
       main = "Miles per Gallon on Weight", panel = my_panel)
```

4. 分组变量

通过添加条件变量（x ~ y | A + B），可以创建出各个水平下的面板。若想要把不同水平的图形结果叠加到一起，

则可以将变量设定为分组变量（group 参数），其具体用法如下所示。

graph_function(formula, data=, qroup=v)

例子：

以 iris 数据集为例，绘制 Sepal.Length（花萼长度）与 Sepal.Width（花萼宽度）的散点图，

并根据 Species（鸢尾花种类）对数据进行分组。

```
library('lattice')
xyplot(Sepal.Length ~ Sepal.Width, group = Species, data = iris,
       pch = 1:3, col = 1:3, main = 'Sepal.Length VS Sepal.Width',
       key = list(space = "right", title = "Species", cex.title = 1, cex = 1,
                  text = list(levels(factor(iris$Species))),
                  points=list(pch = 1:3, col= 1:3)))
```

5. 图形组合

以 iris 数据集为例，在同一个画布上分别 Sepal.Length（花萼长度）与 Sepal.Width（花萼宽度）的散点图，

其中左图是以 Species（鸢尾花种类）为条件变量的栅栏图，右图是根据 Species（鸢尾花种类）分组的散点图。

```
library(lattice)
graph1 <- xyplot(Sepal.Length ~ Sepal.Width | Species,
data = iris, main = '栅栏图')
graph2 <- xyplot(Sepal.Length ~ Sepal.Width, group = Species, data = iris,
main = '散点图1')
graph3 <- xyplot(Petal.Length ~ Petal.Width, group = Species, data = iris,
main = '散点图2')
```

```
# split参数
plot(graph1, split = c(1,1,3,1))
plot(graph2, split = c(2,1,3,1), newpage = FALSE)
plot(graph3, split = c(3,1,3,1), newpage = FALSE)
# position参数，绘图效果同上
plot(graph1, position = c(0, 0, 1/3, 1))
plot(graph2, position = c(1/3, 0, 2/3, 1), newpage = FALSE)
plot(graph3, position = c(2/3, 0, 1, 1), newpage = FALSE)
```

**lattice 包中包含的基本绘图函数及相关绘图对象**

| 函数名（graph_function） | 函数功能 | 绘制对象（formula） |
|---|---|---|
| barchart | 条形图 | 数组，表达式，矩阵，数值型向量，表格 |
| dotplot | 点图 | 数组，表达式，矩阵，数值型向量，表格 |
| histogram | 直方图 | 因子，表达式，数值型向量 |
| densityplot | 核密度图 | 表达式，数值型向量 |
| stripplot | 带状图 | 表达式，数值型向量 |
| qqmath | Q-Q图 | 表达式，数值型向量 |
| qq | Q-Q图 | 表达式 |
| bwplot | 箱线图 | 表达式，数值型向量 |
| xyplot | 散点图 | 表达式 |
| splom | 散点图矩阵 | 数据框，表达式，矩阵 |
| levelplot | 三维水平图 | 数组，表达式，矩阵，表格 |
| contourplot | 三维等高线图 | 数组，表达式，矩阵，表格 |
| cloud | 三维散点图 | 表达式，矩阵，表格 |
| wireframe | 三维曲面图 | 表达式，矩阵 |

图 25: lattice 基本绘图函数

其通用函数格式如下所示:

graph_function(formula, data = , options)

### 3.5.2 使用 ggplot2 包绘图

ggplot2 的核心理念是将绘图与数据分离，数据相关的绘图与数据无关的绘图分离，按图层作图。

1.qplot qplot 的用法和 R base 包的 plot 函数很相似，其使用格式如下所示。

qplot(x, y = NULL, ..., data, facets = NULL, margins = FALSE, geom = "auto",

stat = list(NULL), position = list(NULL), xlim = c(NA,NA), ylim = c(NA, NA),

log = "", main = NULL,xlab = deparse(substitute(x)),

ylab = deparse(substitute(y)), asp = NA)

qplot 函数参数：

| 常见参数 | 描述 |
|---|---|
| data | 数据框（data.frame）类型；如果有这个参数，那么x，y的名称必需对应数据框中某列变量的名称 |
| facets | 图形/数据的分面，这是ggplot2作图比较特殊的一个概念，它把数据按某种规则进行分类，每一类数据做一个图形，所以最终效果就是一页多图 |
| geom | 图形的几何类型（geometry），这又是ggplot2的作图概念。ggplot2用几何类型表示图形类别，比如point表示散点图、line表示曲线图、bar表示柱形图等。 |
| stat | 图形的统计类型（statistics），这个更加特殊。直接将数据统计和图形结合，这是ggplot2强大和受欢迎的原因之一 |
| position | 可对图形或者数据的位置调整。相同数据的几何对象位置相同，是放在一个位置相互覆盖还是用别的排列方式：dodge为并排模式；fill为堆叠模式，并归一化为相同的高度；stack为纯粹的堆叠模式；jitter会在X和Y两个方向增加随机的扰动来防止对象之间的覆盖 |
| margins | 逻辑值，表示是否显示边界 |
| ... | 其他参数与plot函数的参数类似 |

图 26: qplot 函数参数

```
library(ggplot2)
qplot(Species, Sepal.Length, data = iris, geom = "boxplot", fill = Species,
      main = "依据种类分组的花萼长度箱线图")
qplot(Sepal.Length, Sepal.Width, data = iris, colour = Species, shape = Species,
      main = "绘制花萼长度和花萼宽度的散点图")
```

2.ggplot2 包的语言逻辑

通过 plot 与 ggplot2 的实际例子对比来说明。

```
plot(iris$Sepal.Length, iris$Sepal.Width)
library(ggplot2)
ggplot(data= iris, aes(x = Sepal.Length, y = Sepal.Width)) +  #绘制底层画布
geom_point(color = "darkred")  #在画布上添加点
```

ggplot 的绘图有以下几个特点:

- 有明确的起始（以 ggplot 函数开始）与终止（一句语句一幅图）。
- ggplot2 语句可以理解为一句语句绘制一幅图，然后进行图层叠加，而叠加是通过 “+” 号把绘图语句拼接实现的。ggplot 函数的使用格式如下所示:
  ggplot(data = NULL, mapping = aes(), ..., environment = parent.frame())
  **示例:**
  data = iris 时，mapping = aes(x = Sepal.Length, y = Sepal.Width) 表示将花萼长度作为 x 轴变量，花萼宽度作为 y 轴变量。如果需要将 Species 映射
  到形状或者颜色属性，可以添加参数 shape = Species 或者 colour = Species。

```
ggplot(data = iris, aes(x = Sepal.Length, y = Sepal.Width, colour = Species,
          shape = Species))  # 底层画布
```

ggplot2 中可用的几何对象函数:

| 几何对象函数 | 描述 |
|---|---|
| geom_abline | 线：由斜率和截距指定 |
| geom_area | 面积图 |
| geom_bar | 条形图 |
| geom_bin2d | 二维封箱的热图 |
| geom_blank | 空的几何对象，什么也不画 |
| geom_boxplot | 箱线图 |
| geom_contour | 等高线图 |
| geom_crossbar | Crossbar图（类似于箱线图，但没有触须和极值点） |
| geom_density | 密度图 |
| geom_density2d | 二维密度图 |
| geom_errorbar | 误差线（通常添加到其他图形上，比如柱状图、点图、线图等） |
| geom_errorbarh | 水平误差线 |
| geom_freqploy | 频率多边形（类似于直方图） |
| geom_hex | 六边形图（通常用于六边形封箱） |
| geom_histogram | 直方图 |

图 27: ggplot 几何对象函数

| | |
|---|---|
| geom_hline | 水平线 |
| geom_jitter | 点、自动添加了扰动 |
| geom_line | 线 |
| geom_linerange | 区间，用竖直线表示 |
| geom_path | 几何路径，由一组点按顺序链接 |
| geom_point | 点 |
| geom_pointrange | 一条垂直线，线的中间有一个点(与Crossbar图和箱线图有关) |
| geom_polygon | 多边形 |
| geom_quantile | 一组分位数线（来自分位数回归） |
| geom_rect | 二维的长方形 |
| geom_ribbon | 彩虹图 |
| geom_rug | 触须 |
| geom_segment | 线段 |
| geom_smooth | 平滑的条件均值 |
| geom_step | 阶梯图 |
| geom_text | 文本 |
| geom_tile | 瓦片（即一个个的小长方形或多边形） |

如果将数据定义在 ggplot 函数中，那么所有图层都可以共用这个数据；如果将数据定义在 geom_point 函数中，
那么这个数据就只供这个几何对象使用。
统计类型 stat 是指对数据所应用的统计类型/方法，ggplot2 为每一种几何类型指定了一种默认的统计类型.

### 标尺设置

- scale_*_continuous：将数据的连续取值映射为图形属性的取值。
- scale_*_discrete：将数据的离散取值映射为图形属性的取值。
- scale_*_identity：使用数据的值作为图形属性的取值。
- scale_*_mannual：将数据的离散取值作为手工指定的图形属性的取值。

示例：
随机从 iris 数据集的 150 个样本中抽取 100 个样本，并绘制条形图反映 100 个样本中各个鸢尾花种类的数量情况。

```
set.seed(1234)  # 设置随机种子
my_iris <- iris[sample(1:150, 100, replace = FALSE),]  # 随机抽样
p <- ggplot(my_iris) + geom_bar(aes(x = Species, fill = Species))
p$scales  # 查看p的标尺参数
p + scale_fill_manual(
    values = c("orange", "olivedrab", "navy"),  # 颜色设置
    breaks = c("setosa", "versicolor", "virginica"),  # 图例和轴要显示的分段点
    name = "my_Species",  # 图例和轴使用的名称
    labels = c("set", "ver", "vir")  # 图例使用的标签
```

在这个实际例子，可以通过修改标尺参数做前后对比图，进而理解标尺在 ggplot2 包中的作用。
ggplot2 使用技巧：

- 使用 scale_color_manual 或 scale_color_brewer 函数修改图形的颜色。
- ggplot2 默认的坐标系是笛卡尔坐标系，
- 分组绘图 (facet_grid 函数)
- 保存图片（ggsave(filename,width,height,...)

### 3.6 作业

1. 利用 p2p 数据，要求学生清洗数据，得到订单的最后统计数据。
2. 要求利用 lattice,ggplot2 分别画图（7 种图）

# 4 第四章 R 语言实战中医证型关联规则挖掘

教学目的：

1. 借助三阴乳腺癌患者的病理信息，挖掘患者的症状与中医证型之间的关联关系，从而了解数据挖掘常规流程；
2. 掌握 Apriori 关联规则算法。

教学重难点：

1. 重点：掌握 Apriori 关联规则算法；
2. 难点：了解数据挖掘常规流程；

### 4.1 背景与挖掘目标

### 4.2 分析方法与过程

### 4.3 上机操作

# 5 第五章航空公司客户价值分析

教学目的：

1. 熟悉航空公司客户价值分析的步骤与流程，了解RFM模型的基本原理；
2. 掌握K-Means 算法的基本原理；
3. 构建航空客户价值分析的关键特征，比较不同类别客户的客户价值，制定相应的营销策略。

教学重难点：

1.重点：掌握K-Means算法的基本原理；
2.难点：了解RFM 模型的基本原理；

## 5.1 背景与挖掘目标

## 5.2 分析方法与过程

## 5.3 上机操作